

ANÁLISE DE RISCO SISTÊMICO E CONTÁGIO EM FUNDOS DE INVESTIMENTO IMOBILIÁRIO VIA TEORIA DOS GRAFOS

2025015393 - Ana Paula Gomes Jacó

2022012137 - Bianca Salvador

2023000650 - Isaac Davi Mendonça Viana

2022002097 - Laura Raimundi Dias Jesus

CMAC03 - ALGORITMOS EM GRAFOS

Prof. Rafael Frinhani



INSTITUTO DE
MATEMÁTICA E
COMPUTAÇÃO

UNIFEI - Itajubá



Análise de Risco Sistêmico e Contágio em Fundos de Investimento Imobiliário via Teoria dos Grafos

Resumo

A análise de risco sistêmico no mercado financeiro tem dependido historicamente de métricas fundamentalistas estáticas, que falham em capturar as complexas interdependências de liquidez em cenários de crise. Este trabalho propõe uma abordagem baseada em Econofísica e Teoria de Redes Complexas para mapear o mercado brasileiro de fundos imobiliários. Através da construção de um PMFG, extraímos a topologia primária do mercado, culminando num estudo que implementa um motor de *cross-benchmarking* determinístico fundamentado na Metodologia de Raj Jain, avaliando algoritmos de aprendizado não supervisionado e métricas de centralidade. A abordagem permite identificar padrões de similaridade, comunidades de comportamento, fundos com maior influência sistêmica e possíveis mecanismos de propagação de risco, fornecendo uma visão complementar à análise tradicional. Como produto final, toda a esteira analítica foi encapsulada num repositório no *GitHub*¹ com um terminal interativo em ambiente *web*, fornecendo uma ferramenta visual de *hedge* topológico e *Data Science* para investidores e pesquisadores.

Palavras-chave: Teoria de Redes, Econofísica, Risco Sistêmico, PMFG, Machine Learning, IFIX.

1 Introdução

O mercado brasileiro de Fundos de Investimento Imobiliário (FIIs) tem apresentado um crescimento expressivo e contínuo, consolidando-se como um dos principais veículos para investidores que buscam a democratização do acesso ao setor de *Renda Variável*, diversificação de portfólio e geração de renda passiva recorrente. Contudo, o processo decisório tradicional de alocação de capital neste setor frequentemente repousa sobre a análise isolada de indicadores fundamentalistas estáticos — como o rendimento mensal de dividendos (*Dividend Yield*), a valor patrimonial por cota (P/VP) e a classificação setorial instituída pela B3 (ex.: lajes corporativas, galpões logísticos, etc.)²

Essa limitação pode gerar a chamada *ilusão de diversificação*. Ao ignorar a complexa teia de interdependências sistêmicas e o risco de contágio financeiro implícito, modelos tradicionais tratam ativos como entidades independentes. Na realidade, fundos de segmentos nominais distintos podem apresentar comportamentos de mercado quase idênticos devido à exposição a indexadores macroeconômicos semelhantes (CDI,

IPCA), ao compartilhamento de grandes inquilinos-âncora ou à sensibilidade comum às flutuações da taxa básica de juros (Selic). Em momentos de estresse de mercado, essas correlações ocultas se acentuam, desencadeando um efeito dominó que desfaz carteiras teoricamente protegidas.

Este trabalho recorre aos preceitos da Econofísica e da filtragem topológica planar via *Planar Maximally Filtered Graph* (PMFG)³. Ao restringir a geometria da rede à planaridade de Euler ($E \leq 3V - 6$), o PMFG extrai a espinha dorsal de risco do ecossistema sem isolar vértices e preservando laços triangulares fundamentais que representam rotas secundárias de liquidez.

Disto deste cenário e a fim de operacionalizar esses conceitos e aproximar a teoria computacional da inteligência de negócios, desenvolveu-se este artigo e um framework denominado de *Moir Analytics*, um ecossistema de *Data Science* aplicada cujo nome evoca as Moiras da mitologia clássica — as tecelãs que controlavam os fios invisíveis do destino. O sistema analisa as séries temporais dos retornos logarítmicos dos ativos do IFIX, converte correlações financeiras em distâncias topológicas e aplica algoritmos de *Machine Learning* não supervisionado para agrupar e auditar o comportamento do mercado. O desenvolvimento científico e o ciclo de vida do artefato foram estruturados sob o CRISP-NET⁴, garantindo reprodutibilidade e alinhamento sistemático entre os objetivos de negócio e as modelagens matemáticas de grafos.

As principais contribuições e objetivos específicos desta pesquisa estruturam-se em:

1. Construir uma representação em grafo do mercado de FIIs a partir das correlações entre os retornos históricos dos fundos;
2. Filtrar as conexões mais relevantes utilizando o *Planar Maximally Filtered Graph* (PMFG), reduzindo o ruído da matriz de correlação sem perder sua estrutura topológica;
3. Identificar fundos com maior influência na rede por meio de métricas de centralidade, avaliando seu potencial de propagação de risco sistêmico;
4. Detectar comunidades de fundos com comportamento semelhante e compará-las com a classificação setorial oficial da B3;
5. Avaliar a robustez da rede por meio de simulações de estresse, analisando os impactos da remoção dos principais nós sobre a conectividade do mercado.

¹https://github.com/isaacdavi/fiis_graphs

²Mantegna & Stanley (1999)

³Tumminello et al. (2005)

⁴Acuña-Cid et al. (2025)

2 Referencial Teórico e Trabalhos Relacionados

A construção de um modelo computacional capaz de mapear o risco sistêmico e o contágio de liquidez no mercado de capitais exige uma convergência interdisciplinar entre a Teoria de Redes Complexas, a Física Estatística (Econofísica) e o Aprendizado de Máquina Não Supervisionado. Esta seção delimita o estado da arte, estabelece os formalismos matemáticos das estruturas topológicas e fundamenta as métricas que sustentam a esta pesquisa.

2.1 Trabalhos Relacionados

A aplicação da Teoria de Redes Complexas na Econofísica tem ganhado força substancial para a compreensão da mecânica de crises financeiras e da propagação de risco sistêmico. Em vez de modelar ativos financeiros como elementos independentes, essa abordagem representa o mercado como uma rede de interdependências construída a partir das correlações entre os retornos dos ativos, permitindo analisar como choques locais podem se propagar pela estrutura global do sistema.

Um dos trabalhos mais influentes nessa linha foi desenvolvido por Pozzi et al. (2013), que investigaram o mercado acionário norte-americano utilizando grafos filtrados topologicamente, em especial o *Planar Maximally Filtered Graph* (PMFG). Os autores construíram redes de correlação a partir das séries históricas de aproximadamente 300 ações negociadas na bolsa americana e utilizaram diferentes métricas de centralidade, como *Degree*, *Betweenness*, *Closeness*, *Eccentricity* e *Eigenvector Centrality*, para distinguir empresas localizadas nas regiões centrais e periféricas da topologia financeira.

Diferentemente da literatura tradicional baseada exclusivamente na otimização média-variância de Markowitz, o estudo demonstra que a posição topológica ocupada por um ativo na rede contém informação adicional sobre sua exposição ao risco sistêmico. A partir dessa representação, os autores compararam carteiras compostas exclusivamente por ativos centrais, periféricos, aleatórios e pelo conjunto completo do mercado, avaliando indicadores como razão sinal-ruído (retorno médio dividido pelo desvio padrão), probabilidade de retornos positivos, *Sharpe Information Ratio*, excesso de retorno em relação ao índice de mercado e coeficiente beta.

Os resultados mostraram, de forma consistente, que carteiras compostas por ativos localizados nas periferias do PMFG apresentam menor risco, maior probabilidade de retornos positivos e desempenho igual ou superior às carteiras compostas por ativos centrais, mesmo quando ponderadas segundo o modelo de Markowitz. Os autores argumentam que ativos centrais concentram elevada conectividade e tornam-se mais suscetíveis aos efeitos de comportamento coletivo (*herd effect*), absorvendo com maior intensidade choques sistêmicos durante períodos de crise. Em contraste, ativos periféricos apresentam menor acoplamento estrutural com o restante da rede, funcionando naturalmente como elementos amortecedores da propagação de risco financeiro.

O presente trabalho estende essa hipótese para um domínio ainda pouco explorado pela literatura: o mercado brasileiro de Fundos de Investimento Imobiliário (IFIX). Enquanto Pozzi, Di Matteo e Aste validaram empiricamente essa estratégia para ações norte-americanas, esta pesquisa investiga se

o mesmo comportamento topológico permanece válido para o nosso mercado brasileiro.

No escopo do risco sistêmico, Battiston et al. (2012) introduziram uma mudança paradigmática na literatura financeira ao demonstrarem que a vulnerabilidade de um sistema não depende exclusivamente do porte econômico das instituições, mas também da posição estrutural que elas ocupam na rede de interdependências financeiras. Esse conceito, denominado *Too Central to Fail*, amplia a tradicional hipótese do *Too Big to Fail* ao evidenciar que instituições altamente conectadas atuam como canais privilegiados para a propagação de choques e perdas ao longo de todo o mercado, tornando a centralidade um fator determinante para a avaliação do risco sistêmico.

O estudo de Battiston concentra-se principalmente em redes de crédito interbancário e nas relações de exposição entre instituições financeiras e o Federal Reserve, utilizando métricas de centralidade para quantificar a importância sistêmica dos agentes econômicos. Inspirado nesse paradigma, o presente trabalho transpõe essa abordagem para o mercado brasileiro de Fundos de Investimento Imobiliário (IFIX), ainda pouco explorado. A estrutura proposta é construída a partir das correlações entre os retornos logarítmicos dos FIIs, permitindo modelar o contágio financeiro por similaridade comportamental. Nesse contexto, a nossa pesquisa incorpora simulações de Teste de Estresse (*Targeted Attack*) baseadas na *Betweenness Centrality* para identificar “Super-Hubs” de liquidez, demonstrando que a remoção direcionada de poucos fundos altamente centrais é suficiente para fragmentar significativamente a conectividade do ecossistema do IFIX.

No contexto nacional, Tabak et al. (2010) realizaram um dos primeiros estudos sistemáticos sobre a aplicação da Teoria de Redes Complexas ao mercado financeiro brasileiro. Investigando a topologia das redes formadas por ativos do índice Ibovespa, os autores demonstraram que o mercado acionário nacional apresenta estruturas complexas de correlação, concentração de conectividade e organização hierárquica semelhantes às observadas em mercados internacionais, consolidando a Econofísica como uma abordagem capaz de revelar relações estruturais invisíveis às análises tradicionais.

Embora pioneiro, o estudo de Tabak et al. permaneceu restrito ao mercado acionário, deixando em aberto a investigação dessas propriedades no mercado brasileiro de Fundos de Investimento Imobiliário. Diante do crescimento do IFIX e da crescente relevância dos FIIs como instrumento de investimento na renda variável, torna-se pertinente verificar se fenômenos como contágio, centralidade e formação de comunidades também se manifestam nesse segmento, cuja dinâmica econômica difere substancialmente daquela observada nas ações.

Nesse cenário, o principal *gap* de pesquisa preenchido por este trabalho consiste na aplicação desse arcabouço teórico exclusivamente ao mercado de FIIs. Por meio da filtragem topológica via PMFG, métricas de centralidade, detecção de comunidades e do desenvolvimento de um framework web interativo e profundo *Data Science*, esta pesquisa demonstra que os mecanismos de propagação de risco e a limitação das classificações setoriais nominais da B3 também caracterizam o setor de *Real Estate*, convertendo evidências da literatura em uma ferramenta computacional de apoio à análise e à tomada de decisão.

2.2 Detalhamento do Problema

O mercado brasileiro de Fundos de Investimento Imobiliário (FIIs) reúne ativos distribuídos entre diferentes segmentos, como logística, shoppings, lajes corporativas, recebíveis imobiliários e fundos híbridos. Embora essa classificação organize o mercado, ela não representa integralmente as relações de dependência entre os fundos, pois ativos de setores distintos podem exibir comportamentos semelhantes em função de fatores macroeconômicos, indexadores, exposição geográfica, perfil de inquilinos ou condições de liquidez.

Na prática, decisões de investimento frequentemente baseiam-se em indicadores individuais, como *Dividend Yield*, valor patrimonial ou liquidez diária. Entretanto, tais métricas analisam cada fundo de forma isolada, desconsiderando a estrutura de interdependência existente entre os ativos. Essa limitação dificulta a identificação de grupos de fundos com comportamento semelhante, bem como de ativos potencialmente relevantes para a propagação de choques financeiros e do risco sistêmico.

Diante desse cenário, este trabalho propõe modelar o mercado de FIIs como uma rede complexa, na qual cada fundo é representado por um vértice e as relações de similaridade entre seus retornos são representadas por arestas ponderadas. Essa abordagem permite converter relações estatísticas em uma estrutura topológica passível de análise por meio de técnicas provenientes da Teoria dos Grafos e da Econofísica.

2.3 Econofísica e o Espaço Métrico Financeiro

A construção de redes financeiras em Econofísica baseia-se na representação dos ativos por meio de séries temporais de retornos, em vez de seus preços absolutos. Essa abordagem reduz os efeitos da não estacionariedade dos preços e permite comparações estatísticas consistentes entre ativos de diferentes magnitudes. Conforme observado por [Osborne \(1959\)](#), a dinâmica dos preços pode ser aproximada por um movimento Browniano multiplicativo, justificando o emprego dos retornos logarítmicos como variável fundamental da análise.

Assim, considerando o preço de fechamento ajustado $P_i(t)$ do ativo i no instante t , define-se seu retorno logarítmico diário como

$$R_i(t) = \ln \left(\frac{P_i(t)}{P_i(t-1)} \right). \quad (1)$$

Os retornos logarítmicos apresentam propriedades matemáticas que os tornam particularmente adequados para análise financeira, pois transformam variações multiplicativas em incrementos aditivos, reduzem efeitos da não estacionariedade dos preços e permitem comparar ativos de diferentes escalas. Essas características favorecem a estimação da correlação linear de Pearson, utilizada neste trabalho para quantificar a dependência entre os retornos dos ativos.

Sejam dois ativos i e j , o coeficiente de correlação linear de Pearson é calculado a partir da covariância entre seus retornos logarítmicos dividida pelo produto de seus respectivos desvios padrão,

$$\rho_{i,j} = \frac{\text{Cov}(R_i, R_j)}{\sigma_i \sigma_j}. \quad (2)$$

A partir dessa matriz de correlação, [Mantegna & Stanley \(1999\)](#) propôs uma transformação capaz de converter coeficientes de correlação em distâncias geométricas que satisfazem rigorosamente os axiomas de um espaço métrico (não negatividade, identidade dos indiscerníveis, simetria e desigualdade triangular). A distância euclidiana sincronizada entre dois ativos é definida por

$$d_{i,j} = \sqrt{2(1 - \rho_{i,j})}, \quad (3)$$

a qual estabelece um mapeamento do intervalo estatístico $\rho_{i,j} \in [-1, 1]$ para o domínio geométrico $d_{i,j} \in [0, 2]$. Dessa forma, pares de ativos cujos retornos evoluem de maneira perfeitamente sincronizada ($\rho = 1$) apresentam distância nula ($d = 0$), enquanto ativos perfeitamente anticorrelacionados ($\rho = -1$) encontram-se separados pela distância máxima ($d = 2$). Essa transformação constitui a base para a construção de redes financeiras, permitindo interpretar relações estatísticas entre ativos sob uma perspectiva geométrica e topológica, sobre a qual são posteriormente aplicados algoritmos como o MST.

2.4 Planar Maximally Filtered Graph (PMFG)

Embora a Árvore Geradora Mínima (MST) tenha sido a primeira técnica empregada na filtragem de redes financeiras [Mantegna & Stanley \(1999\)](#), sua estrutura em árvore elimina ciclos e reduz significativamente a quantidade de relações preservadas.

Como alternativa, [Tumminello et al. \(2005\)](#) propuseram o PMFG, algoritmo que insere as arestas em ordem crescente de distância, preservando a restrição de planaridade.

Para um grafo planar com V vértices, o número máximo de arestas é dado por:

$$E \leq 3V - 6 \quad (4)$$

Assim, considerando os 77 FIIs utilizados neste trabalho, o PMFG preserva exatamente 225 conexões, mantendo apenas as relações mais relevantes da rede sem comprometer sua estrutura topológica. Também, esta abordagem produz resultados superiores aos métodos baseados em limiares arbitrários (*threshold*), pois preserva simultaneamente a conectividade global e a esparsidade da rede.

2.5 Métricas de Centralidade

Após a construção do PMFG, a relevância estrutural de cada Fundo de Investimento Imobiliário (FII) é quantificada por métricas de centralidade da Teoria de Redes Complexas. Essas medidas permitem identificar ativos estrategicamente posicionados na rede e avaliar sua contribuição para a propagação de informações, transmissão de choques financeiros e concentração do risco sistêmico.

Cada métrica enfatiza uma característica distinta da topologia da rede, como influência global, intermediação entre comunidades, proximidade em relação aos demais vértices ou importância decorrente da conectividade de seus vizinhos. Neste trabalho foram empregadas quatro métricas amplamente utilizadas na literatura.

2.5.1 Eigenvector Centrality

A *Eigenvector Centrality*⁵ quantifica a influência de um vértice considerando não apenas seu número de conexões, mas também a importância dos vértices aos quais está conectado. Sua definição é dada pelo autovetor principal da matriz de adjacência,

$$Ax = \lambda x, \quad (5)$$

em que A representa a matriz de adjacência, x o vetor de centralidades e λ o maior autovalor de A . No contexto financeiro, elevados valores de *Eigenvector Centrality* identificam fundos conectados aos principais núcleos da rede, caracterizando potenciais *hubs* de influência e risco sistêmico.

2.5.2 Betweenness Centrality

A *Betweenness Centrality*⁶ mede a frequência com que um vértice pertence aos menores caminhos entre pares de vértices da rede,

$$g(v) = \sum_{s \neq v \neq t} \frac{\sigma_{st}(v)}{\sigma_{st}}, \quad (6)$$

onde σ_{st} representa o número de caminhos mínimos entre s e t , e $\sigma_{st}(v)$ aqueles que passam por v . Em redes financeiras, elevados valores de *Betweenness* caracterizam fundos que atuam como pontes entre comunidades, favorecendo a propagação de choques entre diferentes segmentos do mercado.

2.5.3 PageRank

Originalmente proposto para classificação de páginas Web, o algoritmo *PageRank*⁷ estima a importância de um vértice a partir da estrutura global da rede,

$$PR(v) = \frac{1-d}{N} + d \sum_{t \in M(v)} \frac{PR(t)}{L(t)}, \quad (7)$$

onde d é o fator de amortecimento, N o número de vértices, $M(v)$ o conjunto de vizinhos de v e $L(t)$ o número de conexões de t . No contexto financeiro, essa métrica identifica ativos que acumulam influência estrutural ao longo da rede de correlações.

2.5.4 Closeness Centrality

A *Closeness Centrality*⁸ mede a proximidade média de um vértice em relação aos demais elementos da rede,

$$C(v) = \frac{N-1}{\sum_{t \neq v} d(v, t)}, \quad (8)$$

onde $d(v, t)$ representa a distância geodésica entre os vértices v e t . Em redes financeiras, elevados valores de *Closeness* indicam ativos com maior potencial para disseminar rapidamente informações ou choques ao longo da estrutura topológica.

Em conjunto, as métricas de *Eigenvector*, *Betweenness*, *PageRank* e *Closeness* fornecem perspectivas complementares sobre a posição estrutural dos FIIs na rede. Enquanto a primeira identifica os principais núcleos de influência, a segunda evidencia vértices de intermediação, o *PageRank* estima a influência acumulada e a *Closeness* avalia o potencial de propagação de informações e choques financeiros.

2.6 Detecção de Comunidades

A detecção de comunidades tem por objetivo identificar subconjuntos de vértices mais densamente conectados entre si do que com o restante da rede. No contexto financeiro, essas comunidades representam grupos de FIIs sujeitos a fatores econômicos semelhantes ou padrões comuns de propagação do risco sistêmico. Neste trabalho foram avaliados os algoritmos Louvain, Greedy Modularity, Girvan-Newman e Label Propagation.

2.6.1 Algoritmo de Louvain

O algoritmo de Louvain, proposto por Blondel et al. (2008), é um método heurístico de otimização hierárquica cuja finalidade consiste em maximizar a modularidade da rede. A modularidade mede o quanto a densidade de conexões observada dentro das comunidades excede aquela esperada em uma rede aleatória equivalente (modelo nulo).

Sua função objetivo é dada por

$$Q = \frac{1}{2m} \sum_{i,j} \left[A_{ij} - \frac{k_i k_j}{2m} \right] \delta(c_i, c_j), \quad (9)$$

onde Q representa a modularidade da partição, k_i e k_j representam os graus ponderados dos vértices, m corresponde ao peso total da rede e $\delta(c_i, c_j)$ é o Delta de Kronecker, assumindo valor 1 quando i e j pertencem à mesma comunidade e 0 caso contrário.

2.6.2 Greedy Modularity

Como método comparativo ao Louvain, empregou-se o algoritmo Greedy Modularity⁹. Trata-se de uma abordagem aglomerativa hierárquica na qual cada vértice inicia como uma comunidade independente e, iterativamente, são realizadas as fusões que produzem o maior incremento imediato da modularidade.

O ganho obtido ao unir duas comunidades é expresso por

$$\Delta Q = \frac{A_{ij}}{m} - \frac{k_i k_j}{2m^2}, \quad (10)$$

onde ΔQ representa o incremento de modularidade decorrente da fusão das comunidades.

2.6.3 Girvan-Newman

O algoritmo de Girvan-Newman¹⁰, utiliza uma estratégia divisiva baseada na remoção sucessiva das arestas mais importantes da rede.

⁵Bonacich (1987)

⁶Freeman (1977)

⁷Brin & Page (1998)

⁸Freeman (1977)

⁹Clauset et al. (2004)

¹⁰Girvan & Newman (2002)

A importância de cada aresta é quantificada pela Centralidade de Intermediação de Arestas, definida por

$$C_B(e) = \sum_{s \neq t} \frac{\sigma_{st}(e)}{\sigma_{st}}, \quad (11)$$

onde $C_B(e)$ representa a centralidade da aresta e .

As arestas com maior centralidade são removidas iterativamente, fragmentando progressivamente a rede em comunidades cada vez mais bem definidas. A modularidade é então utilizada para selecionar a partição considerada ótima.

2.6.4 Label Propagation

O algoritmo Label Propagation (LPA), introduzido por [Raghavan et al. \(2007\)](#), constitui um método não supervisionado baseado em consenso local entre vértices vizinhos.

Sua regra de atualização pode ser representada por

$$c_i^{(t+1)} = \arg \max_l \sum_{j \in N(i)} w_{ij} \delta(c_j^{(t)}, l), \quad (12)$$

onde $c_i^{(t+1)}$ representa o novo rótulo atribuído ao vértice i , $N(i)$ corresponde ao conjunto de seus vértices vizinhos, w_{ij} representa o peso da aresta entre i e j e $\delta(c_j^{(t)}, l)$ é o Delta de Kronecker.

Diferentemente dos métodos baseados em otimização de modularidade, o Label Propagation realiza sucessivas atualizações locais até que a rede atinja um estado estável de consenso entre os rótulos das comunidades.

3 Desenvolvimento e Arquitetura Computacional

Esta seção descreve as etapas empregadas na construção do sistema proposto, abrangendo desde o pré-processamento das séries históricas até a geração da rede de correlação, a seleção dos algoritmos de agrupamento, o cálculo das métricas de centralidade e a implementação da aplicação web utilizada para análise dos resultados. O fluxo completo da metodologia é apresentado na Figura 1.




Figura 1: Fluxo metodológico empregado no desenvolvimento do sistema.

3.1 Engenharia de Dados e Higienização Estocástica

Os dados utilizados neste trabalho correspondem às séries históricas de preços de fechamento ajustados dos Fundos de Investimento Imobiliário (FIIs) pertencentes ao IFIX, obtidas por meio da API `yfinance`. Foi considerada uma janela temporal de cinco anos, compreendida entre 01/01/2020 e 01/01/2025, período que inclui eventos relevantes para o mercado brasileiro, como a pandemia de Covid-19 e o ciclo de elevação da taxa Selic.

Antes da construção da rede, os dados passaram por uma etapa de pré-processamento para garantir consistência estatística e reduzir a influência de ativos com baixa representatividade. O processo foi dividido em três etapas:

1. **Filtro de Sobrevivência Temporal:** seja M o número total de dias de pregão na janela de 5 anos. Para cada ativo i , computa-se o vetor de presença histórica V_i . Um fundo é preservado se, e somente se:

$$\frac{\sum(V_i)}{M} \geq 0,75 \quad (13)$$

Este filtro expurga IPOs recentes cujo tamanho amostral reduzido introduziria assimetria crônica na matriz de covariância de longo prazo.

2. **Filtro de Liquidez e Estagnação de Cotação:** ativos com volume de negociação nulo induzem o fechamento de preços à repetição de valores anteriores, mimetizando correlações perfeitas artificiais. Eliminou-se qualquer nó cuja liquidez fosse nula em proporção superior a 25% dos dias úteis regulamentares.
3. **Tratamento de Descontinuidades Corporativas:** para fundos que sofreram interrupções por fusões, cisões ou reestruturações patrimoniais, aplicou-se a técnica de preenchimento progressivo *Forward Fill* (`.ffill()`), garantindo a continuidade do vetor de estados sem ruído por interpolação linear.

Após a sanitização, o universo elegível convergiu para $|V| = 77$ FIIs altamente líquidos, conforme detalhado na Tabela 1. Os preços ajustados foram então convertidos em retornos logarítmicos diários (1)

Tabela 1: Microestrutura dos dados higienizados e partição setorial nominal da B3.

Setor Nominal B3	Ativos Iniciais	Ativos Retidos	Taxa de Sobrevivência (%)
Fundos de Papel (CRIs)	21	19	90,48
Tijolo - Lajes Corporativas	15	14	93,33
Tijolo - Logística & Industrial	11	10	90,91
Tijolo - Renda Urbana	9	9	100,00
Tijolo - Shopping Centers	8	8	100,00
Fundos de Fundos (FoFs)	7	7	100,00
Fundos Híbridos	7	7	100,00
Fundos de Desenvolvimento	4	3	75,00
Fiagro (Cadeia Agrícola)	2	0	0,00
Total Geral (V)	84	77	91,66




Figura 2: Rede PMFG obtida após a filtragem topológica da matriz de correlação dos FIIs. As cores representam os setores da B3.

3.2 A Falha do Limiar Tradicional e a Teoria da Percolação

Uma abordagem frequentemente utilizada para simplificar redes densas consiste na aplicação de um limiar (*threshold*), preservando apenas as arestas cuja correlação satisfaz $\rho_{i,j} \geq \tau$. Entretanto, em redes financeiras esse procedimento pode provocar uma transição de fase descrita pela Teoria da Percolação¹¹, comprometendo a conectividade global da rede.

A Figura 3 ilustra esse comportamento. Para valores reduzidos de τ , a rede permanece praticamente completa, restando um grande número de conexões pouco informativas e dificultando a identificação de estruturas relevantes. Em contrapartida, o aumento do limiar elimina progressivamente as arestas até que a rede se fragmenta em múltiplas componentes desconectadas, inviabilizando a análise global da propagação do risco.

1. **Limiares baixos:** preservam excesso de arestas, produzindo uma rede excessivamente densa e com baixa capacidade de discriminar comunidades.
2. **Limiares elevados:** induzem a fragmentação da rede. No ponto de transição observado ($\tau = 0,16$), restam 617 arestas, porém a rede já se divide em 19 componentes conexas.

Para contornar essa limitação, adotou-se o *Planar Maximally Filtered Graph* (PMFG), que preserva a conectividade global da rede sem sacrificar sua estrutura topológica. Conforme ilustrado na Figura 3, um limiar capaz de produzir aproximadamente o mesmo número de arestas do PMFG ($\tau \approx 0,21$) fragmentaria o mercado em mais de 25 componentes desconectadas, inviabilizando o cálculo de métricas globais de centralidade, como *Eigenvector Centrality* e *PageRank*.

¹¹Albert & Barabási (2002)

3.3 Filtragem Topológica Planar via Construtor PMFG

A partir da matriz de correlação linear de Pearson (2) calculada sobre os retornos logarítmicos dos 77 ativos, derivou-se a matriz de distâncias euclidianas (3) sincronizadas de Mantegna ($D_{77 \times 77}$).

O formalismo do *pipeline* computacional é descrito no Algoritmo.

Algorithm 1: Algoritmo Construtor do *Planar Maximally Filtered Graph* (PMFG)

Data: Matriz de distâncias topológicas $D_{N \times N}$

Result: Grafo planar $G_{PMFG} = (V, E_{PMFG})$ com

$$|E| = 3N - 6 \text{ arestas}$$

- 1 Inicializar $V \leftarrow \{1, 2, \dots, N\}$;
 - 2 $E_{PMFG} \leftarrow \emptyset$;
 - 3 Criar lista L com todos os pares (i, j) ordenados por $d_{i,j}$ crescente;
 - 4 **foreach** aresta $e_{i,j} \in L$ **do**
 - 5 $E_{teste} \leftarrow E_{PMFG} \cup \{e_{i,j}\}$;
 - 6 $G_{teste} \leftarrow (V, E_{teste})$;
 - 7 **if** G_{teste} é planar (via algoritmo de Boyer-Myrvold)
 - 8 **then**
 - 9 $E_{PMFG} \leftarrow E_{teste}$;
 - 10 **end**
 - 11 **if** $|E_{PMFG}| = 3|V| - 6$ **then**
 - 12 **parar**
 - 13 **end**
 - 14 **return** G_{PMFG}
-

O grafo resultante G_{PMFG} retém exatamente $3(77) - 6 = 225$ arestas estáveis, eliminando 92,31% das 2.926 conexões da matriz densa original. Diferentemente da MST — limitada a $|V| - 1 = 76$ arestas acíclicas —, o PMFG injeta 149 arestas adicionais de alta relevância informacional, permitindo a formação de 3-*cliques* e 4-*cliques* que representam loops de retroalimentação financeira impossíveis de capturar na MST.

3.4 O Motor de Benchmarking Multicritério (Metodologia de Raj Jain)

A seleção da configuração algorítmica foi conduzida por meio de um processo de *benchmarking* multicritério inspirado na metodologia de avaliação de desempenho proposta por Raj Jain¹². Diferentemente de abordagens baseadas em tempo de execução, adotou-se um modelo inteiramente determinístico, fundamentado exclusivamente em propriedades topológicas invariantes da rede. Essa decisão foi motivada pela observação de que pequenas oscilações de CPU produziam variações desprezíveis, porém suficientes para alternar a liderança entre heurísticas de desempenho semelhante, comprometendo a reprodutibilidade dos resultados.

O experimento consistiu no cruzamento ortogonal de uma matriz de decisão 4×4 , avaliando quatro algoritmos de detecção de comunidades (*Greedy Modularity*, *Louvain*, *Girvan-Newman* e *Label Propagation*) em conjunto com quatro métri-

¹²Jain (1991)




Figura 3: Análise de Percolação: O Colapso Topológico do Método Threshold

cas de centralidade (*Betweenness*, *Eigenvector*, *Closeness* e *PageRank*).

Cada configuração foi avaliada segundo quatro critérios complementares:

1. **Modularidade (Q) - Peso 35%:** quantifica o grau em que as comunidades apresentam maior densidade de conexões internas do que seria esperado sob o modelo nulo de Newman & Girvan (2004).
2. **Cobertura Topológica (*Coverage*) - Peso 30%:** mede a proporção de arestas internas às comunidades em relação ao número total de arestas da PMFG,

$$\text{Coverage} = \frac{\sum_{i,j} A_{ij} \delta(c_i, c_j)}{|E|_{\text{PMFG}}}. \quad (14)$$

Valores elevados indicam maior retenção das conexões estruturais dentro das comunidades.

3. **Informação Mútua Normalizada (*NMI*) - Peso 20%:** quantifica o grau de concordância entre a partição obtida de forma não supervisionada e a classificação setorial oficial da B3, permitindo avaliar o quanto ambas compartilham informação¹³.
4. **Contraste de Centralidade (*CV*) - Peso 15%:** quantifica a capacidade da métrica de centralidade em distinguir ativos de alta influência estrutural dos demais vértices da rede por meio do Coeficiente de Variação,

$$CV = \frac{\sigma_C}{\mu_C}, \quad (15)$$

em que σ_C representa o desvio-padrão e μ_C a média dos escores de centralidade considerados.

Após a obtenção das métricas, todos os valores foram normalizados para o intervalo $[0, 1]$ em relação ao melhor desempenho observado no experimento. O Índice de Performance (*IP*) foi então calculado por uma combinação linear ponderada, atribuindo maior importância às métricas diretamente relacionadas à qualidade estrutural da partição:

$$IP = \frac{7.Q_{\text{norm}}}{20} + \frac{3.Coverage_{\text{norm}}}{10} + \frac{NMI_{\text{norm}}}{5} + \frac{3.CV_{\text{norm}}}{20} \quad (16)$$

A configuração que apresentou o maior valor de *IP* foi selecionada como a arquitetura definitiva do motor analítico proposto.

¹³Danon et al. (2005)

3.5 Álgebra Linear Ponderada e o Método das Potências

Após a seleção da configuração ótima pelo benchmarking, o PMFG é convertido em uma matriz de adjacência ponderada, uma vez que as métricas espectrais interpretam pesos como intensidade de conexão, enquanto a matriz obtida pela transformação de Mantegna representa distâncias. Assim,

$$A_{i,j} = \begin{cases} \frac{1}{d_{i,j} + \varepsilon}, & e_{i,j} \in E_{\text{PMFG}}, \\ 0, & \text{caso contrário,} \end{cases} \quad (17)$$

onde $\varepsilon = 10^{-4}$ evita singularidades numéricas quando $d_{i,j} = 0$.

A Eigenvector Centrality é obtida pela resolução do problema espectral

$$A\mathbf{x} = \lambda\mathbf{x},$$

utilizando o Método das Potências (*Power Iteration*), que consiste nas iterações

$$\mathbf{y}^{(t)} = A\mathbf{x}^{(t-1)}, \quad (18)$$

$$\mathbf{x}^{(t)} = \frac{\mathbf{y}^{(t)}}{\|\mathbf{y}^{(t)}\|_2}. \quad (19)$$

O algoritmo foi executado até a convergência $\|\mathbf{x}^{(t)} - \mathbf{x}^{(t-1)}\|_2 < 10^{-6}$, ou no máximo 1000 iterações.

Como a matriz de adjacência do PMFG é real, simétrica e não negativa, o Teorema de Perron-Frobenius garante a convergência para o autovetor dominante, cujos valores são posteriormente utilizados como escores de Eigenvector Centrality e na escala visual dos vértices da rede.

4 Resultados e Discussão

As simulações computacionais executadas comprovaram empiricamente a tese central deste estudo: a modelagem por redes complexas expõe vetores de risco e padrões de similaridade comportamental que são matematicamente invisíveis aos indicadores fundamentalistas tradicionais, fornecendo mecanismos acionáveis para a proteção de portfólios no mercado imobiliário (IFIX).

4.1 Aplicação Web

Para facilitar a execução dos experimentos e a análise dos resultados, foi desenvolvida uma aplicação web utilizando o framework Streamlit. A plataforma integra todas as etapas da metodologia, desde a obtenção dos dados até a construção do PMFG, cálculo das métricas de centralidade e identificação das comunidades.

A interface disponibiliza visualizações interativas da rede em duas e três dimensões, desenvolvidas com as bibliotecas PyVis e Plotly, além de permitir ao usuário selecionar diferentes períodos de análise e executar automaticamente todo o pipeline proposto.

Com o objetivo de garantir reprodutibilidade, tanto a aplicação quanto o código-fonte do projeto foram disponibilizados publicamente.^{14 15}

4.2 Benchmarking de Raj Jain: Seleção do Par Ótimo

Após a construção do PMFG, a metodologia de Raj Jain avaliou as configurações algorítmicas sob um modelo determinístico. Baseado exclusivamente em métricas topológicas, o método eliminou oscilações de tempo de execução, garantindo uma seleção pautada unicamente na qualidade estrutural das partições.

Conforme a Figura 4, a avaliação multicritério polarizou a disputa entre as heurísticas *Greedy Modularity* e *Louvain*. Embora ambas apresentem alto desempenho em Modularidade e *Coverage*, o *Greedy Modularity* prevaleceu por seu maior NMI, demonstrando superioridade no equilíbrio entre otimização de rede e a descoberta de estruturas relacionais além da classificação oficial da B3.




Figura 4: Relatório consolidado do benchmarking determinístico. A combinação *Greedy Modularity* + *Betweenness Centrality* apresentou o maior Índice de Performance (IP), sendo selecionada como arquitetura ótima do sistema proposto.

Observou-se ainda que o algoritmo *Girvan-Newman* apresentou elevada cobertura topológica em virtude da formação de comunidades demasiadamente grandes, reduzindo a

granularidade da partição. Por outro lado, a *Betweenness Centrality* demonstrou o maior poder discriminativo entre as métricas de centralidade avaliadas, favorecendo a identificação dos vértices mais relevantes para a propagação do risco sistêmico.

A Tabela 2 apresenta os valores normalizados obtidos para cada configuração avaliada, bem como o Índice de Performance (IP), utilizado como métrica consolidada para comparação entre as alternativas.

Tabela 2: Matriz de decisão multicritério de Raj Jain para seleção da configuração algorítmica.

Configuração Algorítmica	Q_{norm}	Cov_{norm}	NMI_{norm}	CR_{norm}	Índice IP
Louvain + Eigenvector	1,00	0,82	0,81	0,30	0,8031
Louvain + Betweenness	1,00	0,82	0,81	1,00	0,9076
Greedy Mod. + Betweenness	0,99	0,86	1,00	1,00	0,9540
Girvan-Newman + Betweenness	0,69	1,00	0,47	1,00	0,7875
Label Propagation + PageRank	0,73	0,88	0,82	0,27	0,7263

A combinação **Greedy Modularity + Betweenness Centrality** apresentou o maior Índice de Performance (IP = 0,9540), seguida pelas configurações Louvain + Betweenness (IP = 0,9076) e Louvain + Eigenvector (IP = 0,8031). Em razão desse desempenho superior, a configuração Greedy Modularity + Betweenness foi adotada nas análises apresentadas nas próximas subseções.

4.3 Comunidades Detectadas

O algoritmo Greedy Modularity foi aplicado à rede PMFG para identificar comunidades formadas por FIIs com comportamento semelhante ao longo do período analisado. Esses agrupamentos representam conjuntos de ativos fortemente conectados entre si, indicando maior similaridade entre seus retornos.

A Figura 5 apresenta a rede PMFG com os vértices coloridos de acordo com as comunidades identificadas pelo algoritmo.




Figura 5: Rede PMFG com os vértices coloridos de acordo com as comunidades detectadas pelo algoritmo Greedy Modularity.

Observa-se que as comunidades encontradas não coincidem integralmente com a classificação setorial oficial da B3. Fundos pertencentes a diferentes segmentos, como logística, lajes corporativas e shopping centers, aparecem agrupados na

¹⁴<https://fiis-graphs-moira-analytics-terminal.streamlit.app>

¹⁵https://github.com/isaacdavii/fiis_graphs

mesma comunidade devido à elevada correlação entre seus retornos históricos. Da mesma forma, parte dos fundos de papel (CRIs) concentrou-se em comunidades distintas, refletindo um comportamento influenciado por fatores econômicos específicos durante o período analisado.

Esses resultados indicam que a estrutura topológica da rede captura relações entre os FIIs que vão além da classificação setorial tradicional, permitindo identificar padrões de similaridade que não seriam observados apenas pela divisão oficial dos ativos em categorias.

4.4 Análise das Métricas de Centralidade

Após a identificação das comunidades, foram calculadas as métricas de *Eigenvector Centrality* e *Betweenness Centrality* para avaliar a importância estrutural dos vértices dentro da rede PMFG. Essas métricas permitem identificar quais ativos exercem maior influência sobre a conectividade da rede e quais ocupam posições periféricas.

A Figura 6 apresenta a visualização da rede PMFG, na qual o tamanho dos vértices é proporcional ao valor de *Eigenvector Centrality*. Dessa forma, os ativos estruturalmente mais relevantes aparecem representados por nós de maior dimensão.




Figura 6: Visualização da rede PMFG em que o tamanho dos vértices é proporcional ao valor de *Eigenvector Centrality*.

Observa-se que alguns FIIs ocupam posições centrais na rede, apresentando elevada conectividade com outros vértices também importantes. Esses ativos tendem a exercer maior influência estrutural sobre a rede, funcionando como elementos de ligação entre diferentes regiões e comunidades.

Em contrapartida, diversos vértices localizam-se na periferia da rede e apresentam baixos valores de *Eigenvector Centrality* e *Betweenness Centrality*. Esses ativos possuem menor influência sobre a conectividade global e menor participação como intermediários entre diferentes grupos da rede.

A identificação desses perfis fornece informações relevantes para a análise estrutural do mercado de FIIs, permitindo distinguir ativos centrais daqueles com comportamento mais independente.

4.5 Teste de Estresse Computacional (Targeted Attack)

Para auditar a fragilidade estrutural do IFIX, executou-se um *Targeted Attack*: a deleção forçada (remoção de vértices e todas as arestas incidentes) dos 5 FIIs detentores dos maiores coeficientes de *Betweenness Centrality* — os “Super-Hubs” identificados como pontes vitais de liquidez entre os subsetores do mercado.

O impacto topológico foi imediato: o grafo, originalmente 100% conexo, estilhaçou-se em **múltiplos componentes conexos isolados**. A Figura 7 apresenta a anatomia do colapso renderizada pelo Matplotlib: o **Grupo Ciano** manteve-se operacional graças a rotas secundárias de liquidez intra-cluster, enquanto os **Pontos Vermelhos** foram lançados ao isolamento absoluto (órfãos sistêmicos).



Figura 7: Fragmentação da Rede do IFIX após o Teste de Estresse Direcionado

As evidências demonstram uma falha crítica na distribuição de liquidez do mercado imobiliário brasileiro: a estabilidade aparente do IFIX repousa perigosamente sobre um pequeno oligopólio de formadores de mercado. A materialização desta orfandade topológica em cenários reais resultaria no congelamento de *books* de ofertas e falha na precificação por arbitragem — alerta alinhado ao paradigma *Too Central to Fail* de Battiston et al. (2012).

5 Conclusões

O presente estudo logrou pleno êxito em sua premissa fundamental: traduzir os fluxos financeiros e riscos empíricos do mercado imobiliário da B3 (IFIX) para uma topologia matemática dinâmica de redes complexas. Por intermédio das normativas da metodologia CRISP-NET, demonstrou-se que a análise de grafos soluciona lacunas perigosas intrínsecas às métricas convencionais do mercado de capitais, revelando a teia de interdependência que a análise fundamentalista ignora.

Entre os principais resultados obtidos, ratifica-se a superioridade algorítmica da arquitetura PMFG (*Planar Maximally Filtered Graph*) ante a clássica Árvore Geradora Mínima (MST) em aplicações financeiras. O PMFG obteve sucesso em registrar, sem ferir a restrição de planaridade de Euler, os sub-ciclos e laços de dependência cruciais para a análise de contágio de liquidez.

Ademais, o *benchmarking* determinístico de Raj Jain desmistificou premissas heurísticas, provando que a modelagem

via *Betweenness* aliada ao algoritmo *Greedy* compõe a lente analítica mais poderosa do modelo. Essa combinação decifrou a falsa diversificação nominal da B3 e indicou com precisão matemática os vértices periféricos (folhas estruturais) ideais para atuar como “bunkers” em estratégias ativas de *Hedge*.

As comunidades detectadas mostraram que a organização topológica dos FIIs não coincide integralmente com a classificação setorial oficial da B3, sugerindo que ativos pertencentes a diferentes segmentos podem apresentar comportamento semelhante ao longo do período analisado.

Do ponto de vista sistêmico e macroeconômico, a vulnerabilidade atestada pelo teste de estresse computacional (*Targeted Attack*) soa um alerta contundente para investidores e gestores institucionais. A fratura da conectividade do índice IFIX em doze ilhas independentes, causada pela falência simulada de meros cinco formadores de mercado, denuncia uma rede dependente de poucos conglomerados para a manutenção de sua liquidez. Esse resultado reforça a importância das métricas de centralidade para identificar ativos estruturalmente relevantes e demonstra o potencial da abordagem baseada em grafos como ferramenta complementar para análise de similaridade e propagação de risco no mercado de FIIs.

Esses resultados mostram que a abordagem por grafos oferece uma leitura do mercado que vai além do que os indicadores tradicionais conseguem capturar, respondendo ao objetivo proposto pelo trabalho

Limitações do Estudo

O modelo considera apenas dados de preço, deixando de lado informações importantes como vacância dos imóveis, nível de endividamento dos fundos e outros dados. Além disso, a análise é estática: foi construída sobre toda a janela de cinco anos de uma vez, sem observar como as comunidades e os hubs mudam ao longo do tempo. O mercado de fundos imobiliários também é relativamente recente, logo, há uma limitação devido ao tempo de mercado.

Trabalhos Futuros

Como próximos passos, seria interessante explorar grafos dinâmicos com janelas de tempo deslizantes, para acompanhar como a estrutura do mercado evolui. Outra possibilidade é aplicar a mesma metodologia a mercados internacionais de REITs (*Real Estate Investment Trusts*), verificando se os padrões encontrados são específicos ao Brasil ou se se repetem em outros países.

Referências

- Acuña-Cid, H. A., Ahumada-Tello, E., Ovalle-Osuna, Ó. O., Evans, R., Hernández-Ríos, J. E., & Zambrano-Soto, M. A. (2025). Crisp-net: Integration of the crisp-dm model with network analysis. *Machine Learning and Knowledge Extraction*, 7(3), 101.
- Albert, R. & Barabási, A.-L. (2002). Statistical mechanics of complex networks. *Reviews of Modern Physics*, 74(1), 47–97.
- Battiston, S., Puliga, M., Kaushik, R., Tasca, P., & Caldarelli, G. (2012). Debtrank: Too central to fail? financial networks, the fed and systemic risk. *Scientific Reports*, 2, 541.
- Blondel, V. D., Guillaume, J.-L., Lambiotte, R., & Lefebvre, E. (2008). Fast unfolding of communities in large networks. *Journal of Statistical Mechanics: Theory and Experiment*, 2008(10), P10008.
- Bonacich, P. (1987). Power and centrality: A family of measures. *American Journal of Sociology*, 92(5), 1170–1182.
- Brin, S. & Page, L. (1998). The anatomy of a large-scale hypertextual web search engine. *Computer Networks and ISDN Systems*, 30(1-7), 107–117.
- Clauset, A., Newman, M. E. J., & Moore, C. (2004). Finding community structure in very large networks. *Physical Review E*, 70(6), 066111.
- Danon, L., Diaz-Guilera, A., Duch, J., & Arenas, A. (2005). Comparing community structure identification. *Journal of Statistical Mechanics: Theory and Experiment*, 2005(09), P09008.
- Freeman, L. C. (1977). A set of measures of centrality based on betweenness. *Sociometry*, 40(1), 35–41.
- Girvan, M. & Newman, M. E. J. (2002). Community structure in social and biological networks. *Proceedings of the National Academy of Sciences (PNAS)*, 99(12), 7821–7826.
- Jain, R. (1991). *The Art of Computer Systems Performance Analysis: Techniques for Experimental Design, Measurement, Simulation, and Modeling*. New York, NY, USA: Wiley-Interscience.
- Mantegna, R. N. & Stanley, H. E. (1999). *An Introduction to Econophysics: Correlations and Complexity in Finance*. Cambridge, UK: Cambridge University Press.
- Newman, M. E. J. & Girvan, M. (2004). Finding and evaluating community structure in networks. *Physical Review E*, 69(2), 026113.
- Osborne, M. F. M. (1959). Brownian motion in the stock market. *Operations Research*, 7(2), 145–173.
- Pozzi, F., Di Matteo, T., & Aste, T. (2013). Spread of risk across financial markets: better to invest in the peripheries. *Scientific Reports*, 3, 1665.
- Raghavan, U. N., Albert, R., & Kumara, S. (2007). Near linear time algorithm to detect community structures in large-scale networks. *Physical Review E*, 76(3), 036106.
- Sohrabi, H., Esmaeili, S., & Moradi, P. (2026). Community detection via graph regularized symmetric nonnegative matrix tri-factorization. *The Journal of Supercomputing*.
- Tabak, B. M., Serra, T. R., & Cajueiro, D. O. (2010). Topological properties of stock market networks: The case of Brazil. *Physica A: Statistical Mechanics and its Applications*, 389(16), 3240–3249.
- Tumminello, M., Aste, T., Di Matteo, T., & Mantegna, R. N. (2005). A tool for filtering information in complex systems. *Proceedings of the National Academy of Sciences (PNAS)*, 102(30), 10421–10426.

